

# Cálculo Numérico

## Noções básicas sobre erros

### Aritmética de ponto flutuante

Prof. Daniel G. Alfaro Vigo  
dgalfaro@dcc.ufrj.br  
DCC-IM-UFRJ

# Parte I

## Noções básicas sobre erros




Figura : Diagrama para a resolução de problemas reais.

- A obtenção de uma solução numérica para um problema físico por meio da aplicação de métodos numéricos, nem sempre fornece resultados que se encaixam dentro de limites razoáveis.
- Isso acontece mesmo quando o método é adequado e os cálculos são efetuados de uma maneira correta.
- Tal diferença ocorre devido aos **erros acumulados** na conversão dos números para o sistema aritmético da máquina e nas sucessivas operações realizadas, isso é inerente ao processo e, na maioria dos casos, não tem como ser evitado.

# Noções básicas sobre erros

Como podemos avaliar o erro cometido em uma aproximação?

## Erros absoluto e relativo

Seja  $\tilde{x}$  uma aproximação do número real  $x$ . Chamamos de **erro absoluto** a

$$E_x = |x - \tilde{x}|,$$

e de **erro relativo** a

$$\varepsilon_x = \frac{E_x}{|x|} = \left| \frac{x - \tilde{x}}{x} \right|, \quad \text{se } x \neq 0.$$

## Observações:

- O erro absoluto está relacionado com a distância entre  $x$  e  $\tilde{x}$ .
- O erro relativo está mais relacionado com a precisão da aproximação.
- Nas aplicações é importante conhecer **limitantes (ou estimativas)** desses erros.

# Propagação de erros: multiplicação e divisão

O que acontece com os erros quando realizamos operações aritméticas com números aproximados?

Para o caso da multiplicação e divisão, se  $\varepsilon_x$  e  $\varepsilon_y$  são pequenos temos as aproximações

$$E_{x \cdot y} \lesssim |y| E_x + |x| E_y,$$

$$\varepsilon_{x \cdot y} \lesssim \varepsilon_x + \varepsilon_y \quad \longleftarrow \quad \text{OK, o erro fica controlado}$$

$$E_{x/y} \lesssim \frac{|y| E_x + |x| E_y}{y^2},$$

$$\varepsilon_{x/y} \lesssim \varepsilon_x + \varepsilon_y \quad \longleftarrow \quad \text{OK, o erro fica controlado.}$$

Concluimos que nesse caso **os erros se propagam de forma controlada!**

# Propagação de erros: adição e subtração

Para este caso temos as seguintes desigualdades

$$\begin{aligned} |E_x - E_y| &\leq E_{x \pm y} \leq E_x + E_y, \\ \left| \frac{|x|}{|x \pm y|} \varepsilon_x - \frac{|y|}{|x \pm y|} \varepsilon_y \right| &\leq \varepsilon_{x \pm y} \leq \frac{|x|}{|x \pm y|} \varepsilon_x + \frac{|y|}{|x \pm y|} \varepsilon_y. \end{aligned}$$

Observe que se  $x$  e  $y$  são números positivos então

$$\begin{aligned} \varepsilon_{x+y} &\leq \frac{x}{x+y} \varepsilon_x + \frac{y}{x+y} \varepsilon_y \leq \left( \frac{x}{x+y} + \frac{y}{x+y} \right) \max\{\varepsilon_x, \varepsilon_y\} \\ &\leq \underbrace{\left( \frac{x}{x+y} + \frac{y}{x+y} \right)}_{=1} \max\{\varepsilon_x, \varepsilon_y\} \\ \varepsilon_{x+y} &\leq \max\{\varepsilon_x, \varepsilon_y\} \quad \leftarrow \text{OK, o erro fica controlado} \end{aligned}$$

Assim se somamos números com o mesmo sinal ou subtraímos números de sinais diferentes, **os erros se propagam de forma controlada!**

# Propagação de erros: adição e subtração

Considere que  $x$  e  $y$  são números positivos e  $\varepsilon_y = 0$ , então

$$\varepsilon_{x-y} \geq \frac{x}{|x-y|} \varepsilon_x,$$

Assim, quando  $x$  e  $y$  são muito próximos o fator  $\frac{x}{|x-y|}$  ficará muito grande e **o erro inicial será amplificado!**

## Cancelamento catastrófico

Em geral, se subtraímos números muito próximos ou somamos números com sinais diferentes e próximos em modulo poderá acontecer uma perda considerável da precisão.

Este fenômeno é conhecido como **cancelamento catastrófico**.

## Parte II

# Aritmética de ponto flutuante e Norma IEEE 754

# Introdução: como representamos os números?

- No dia a dia, geralmente, usamos a notação decimal para representar os números.
- A notação decimal foi desenvolvida na cultura hindu, em volta do ano 600 d.C.
- Na historia da humanidade já foram usados outros sistemas de numeração:
  - sistema sexagesimal (civilização babilônica, 1750 a.C.)
  - sistema romano (civilização romana 260 a.C.)
  - sistema vigesimal (civilização maia, 200 d.C.)
- Nossos computadores usam a representação binária dos números!

# Introdução: os números reais no computador

- Nos computadores modernos é usado o bit (Binary digit = dígito binário) como a menor unidade de informação que pode ser armazenada.
- Um bit pode tomar apenas os valores 0 ou 1.
- Por isso, nos computadores a representação de números é feita no sistema binário (base dois).
- Mas devido às limitações físicas pode ser usada apenas uma quantidade finita de informação na representação dos números reais, e portanto é necessário fazer aproximações.
- A maioria dos computadores modernos segue a norma IEEE 754 para o tratamento dos números reais, garantindo a portabilidade e compatibilidade dos códigos usados em computação científica.

Para evitar erros computacionais descontrolados precisamos entender como são feitas as representações e aproximações dos números reais, e como elas influenciam os cálculos!

# Representação de ponto fixo e ponto flutuante

## Representação de ponto fixo

Para qualquer base  $\beta \geq 2$  (inteiro), podemos escrever os números reais na forma:

$$\pm(d_I d_{I-1} \dots d_0, d_{-1} d_{-2} \dots)_\beta$$

em que  $d_j \in \{0, 1, \dots, \beta - 1\}$  são os dígitos.

Essa representação corresponde ao número

$$\pm(d_I \cdot \beta^I + \dots + d_0 \cdot \beta^0 + d_{-1} \cdot \beta^{-1} + \dots) =$$

$$\pm(d_I + d_{I-1} \cdot \beta^{-1} + \dots + d_0 \cdot \beta^{-I} + \dots) \cdot \beta^I$$

## Representação de ponto flutuante

$$\pm(d_I, d_{I-1} \dots d_0 \dots) \cdot \beta^I$$

# Representação (binária) de ponto flutuante

Considerando  $\beta = 2$ , para qualquer número real  $x$ , temos que

$$x = (-1)^s (d_0 + d_1 \cdot 2^{-1} + \dots + d_j \cdot 2^{-j} + \dots) \cdot 2^e$$

sinal de  $x$ :  $s \in \{0, 1\}$  ( $0 \rightarrow +$  e  $1 \rightarrow -$ ),

dígitos:  $d_0, d_1, \dots \in \{0, 1\}$ ,

expoente:  $e$  (número inteiro).

## Notação mais compacta

$$x = \pm (d_0, d_1 \dots d_j \dots)_2 \times 2^e$$

### Observações:

- $m = (d_0, d_1 \dots d_j \dots)_2$  é chamado de mantissa de  $x$ .
- A representação está normalizada quando  $d_0 \neq 0$ .
- Para  $x = 0$  não existe nenhuma representação normalizada!

# Representação (binária) de ponto flutuante

## Exemplo 1

Temos as seguintes representações:

$$3 = (0, 11)_2 \times 2^2 = (1, 1)_2 \times 2^1$$

$$5 = (0, 0101)_2 \times 2^4 = (1, 01)_2 \times 2^2.$$

## Observações:

- As representações desses números são finitas.
- Cada número possui apenas uma **representação normalizada**!

## Exemplo 2

Calculando  $3 \div 5$  obtemos

$$3/5 = (0, 1001 \dots 1001 \dots)_2 \times 2^0 = (1, 0011 \dots 0011 \dots)_2 \times 2^{-1},$$

que possui uma **representação de ponto flutuante com infinitos dígitos**!

# Aritmética (finita) de ponto flutuante

## Norma IEEE 754

- Essa norma foi adotada em 1985, e sua última modificação foi introduzida no ano 2008 [754 WG].
- Nessa norma foi introduzido o padrão para a representação de números reais no computador.
- Define diferentes formas para a aproximação dos números reais no computador e os formatos de números de ponto flutuante que devem ser usados.
- Especifica como devem ser realizadas as operações aritméticas e o tratamento de exceções envolvendo números de ponto flutuante.

## Aritmética de ponto flutuante

Modelo simplificado da representação dos números no computador que nos ajuda a entender e avaliar os erros que aparecem nos processos computacionais.

# Aritmética (finita) de ponto flutuante

## Sistema de ponto flutuante

Considere os números inteiros  $p$ ,  $E_{min}$  e  $E_{max}$  tais que  $p \geq 1$ ,  $E_{min} < E_{max}$ .

Chamamos de sistema de ponto flutuante com precisão  $p$  e limites  $E_{min}$ ,  $E_{max}$  para o expoente ao subconjunto  $\mathbb{F}$  dos números reais definido por


$$\mathbb{F} = \{ \pm (d_0, d_1 \dots d_{p-1})_2 \times 2^e \mid d_0 = 1, e \in [E_{min}, E_{max}] \} \cup \{0\}.$$

## Observações:

- Dois números de  $\mathbb{F}$  são iguais, se e somente se suas representações são iguais.
- $\mathbb{F}$  contem  $2^p(E_{max} - E_{min} + 1) + 1$  números.
- Os números não nulos com o menor modulo são  $\pm x_{min}$ , em que  $x_{min} = 2^{E_{min}}$  e os de maior modulo são  $\pm x_{max}$  em que  $x_{max} = (2^p - 1)2^{E_{max}+1-p}$ .

# Aritmética (finita) de ponto flutuante

**Exemplo:** Sistema de ponto flutuante para  $p = 3$ ,  $E_{\min} = -1$  e  $E_{\max} = 2$ . Em a) mostramos todos os números de  $\mathbb{F}$  e em b) mostramos um zoom do intervalo  $[-5, 5]$ . Nesse sistema  $x_{\min} = \frac{1}{4}$  e  $x_{\max} = 14$ .



# Aritmética (finita) de ponto flutuante

## Aproximação de números reais

Está definida a função  $\text{fl} : \mathbb{R} \rightarrow \mathbb{F}$  tal que se  $x \in \mathbb{F}$  então  $\text{fl}(x) = x$ .  
No computador  $x$  é aproximado por  $\text{fl}(x)$ .

## Aritmética de ponto flutuante

Temos um sistema de aritmética de ponto flutuante quando introduzimos em  $\mathbb{F}$  as operações aritméticas elementares

$$x \oplus y \stackrel{\text{def}}{=} \text{fl}(x + y)$$

$$x \ominus y \stackrel{\text{def}}{=} \text{fl}(x - y)$$

$$x \odot y \stackrel{\text{def}}{=} \text{fl}(x \cdot y)$$

$$x \oslash y \stackrel{\text{def}}{=} \text{fl}(x/y).$$

- Devido as aproximações envolvidas pode acontecer que  $x \circledast y \neq x * y$  para  $* \in \{+, -, \cdot, /\}$ .
- Outras propriedades básicas das operações aritméticas também podem falhar.

- São definidos dois formatos básicos de números de ponto flutuante

|                | Precisão simples | Precisão dupla |
|----------------|------------------|----------------|
| $p$ (Precisão) | 24               | 53             |
| $E_{\min}$     | -126             | -1022          |
| $E_{\max}$     | +127             | +1023          |
| Total de Bits  | 32               | 64             |

- Várias formas para determinar as aproximações  $\text{fl}(x)$ , nos discutiremos o truncamento e o arredondamento.
- O resultado da adição, subtração, multiplicação e divisão nas especificações da norma corresponde as operações aritméticas de ponto flutuante  $\oplus$ ,  $\ominus$ ,  $\odot$  e  $\oslash$  em que a aproximação  $\text{fl}$  é feita por arredondamento.

# Aproximações na aritmética de ponto flutuante

Se  $x = 0$  então  $\text{fl}(x) = 0$ .

Se  $x = \pm (1 + d_1 \cdot 2^{-1} + d_2 \cdot 2^{-2} + \dots) \cdot 2^e \neq 0$ .

## Truncamento

$$\text{fl}(x) = x_{\text{trunc}} = \pm (1, d_1 \dots d_{p-1})_2 \times 2^e$$

## Arredondamento

$$\text{fl}(x) = x_{\text{arred}} = \begin{cases} x_{\text{trunc}}, & \text{se } g < 1, \text{ ou, } g = 1 \text{ e } d_{p-1} = 0 \\ x_{\text{trunc}}^{\pm}, & \text{se } g > 1, \text{ ou, } g = 1 \text{ e } d_{p-1} = 1, \end{cases}$$

em que  $x_{\text{trunc}}^{\pm} = x_{\text{trunc}} \pm 2^{e-p+1}$  e  $g = (d_p, d_{p+1} \dots)_2$ .

## Exceções

Quando  $e \notin [E_{\min}, E_{\max}]$ ,  $\text{fl}(x)$  gerará uma exceção: *underflow* se  $e < E_{\min}$  e *overflow* se  $e > E_{\max}$ .

# Erros na aproximação de ponto flutuante

## Truncamento

$$E_x = |x - x_{trunc}| \leq 2^{e-p} \quad \text{e} \quad \epsilon_x = \left| \frac{x - x_{trunc}}{x} \right| \leq \epsilon_{maq} = 2^{-p+1}$$

## Arredondamento

$$E_x = |x - x_{arred}| \leq 2^{e-p-1} \quad \text{e} \quad \epsilon_x = \left| \frac{x - x_{arred}}{x} \right| \leq \frac{\epsilon_{maq}}{2} = 2^{-p}$$

Logo  $\text{fl}(x) = x(1 - \delta_x^{arred})$ , em que  $|\delta_x^{arred}| \leq \epsilon_x^{arred} \leq \epsilon_{maq}/2$ .

- **Os erros relativos estão limitados uniformemente** por uma constante que depende apenas da precisão!
- O arredondamento é mais preciso que o truncamento!
- Na norma IEEE 754
  - $\epsilon_{maq} = 2^{-23} \approx 1.19 \cdot 10^{-7}$  (precisão simples),
  - $\epsilon_{maq} = 2^{-52} \approx 2.22 \cdot 10^{-16}$  (precisão dupla).

# Erros na aritmética de ponto flutuante

- Nas operações aritméticas é usada a função  $\text{fl}(\cdot)$  correspondente ao arredondamento (norma IEEE 754).
- A perda de precisão nos cálculos é provocada pela **acumulação de erros**. Por exemplo, se queremos calcular  $x + y$ , mas temos os dados aproximados  $\tilde{x}, \tilde{y} \in \mathbb{F}$ , o computador nos dá a aproximação

$$x + y \approx \tilde{x} \oplus \tilde{y} = \text{fl}(\tilde{x} + \tilde{y}).$$

- Nesse cálculo são introduzidos vários erros

$$\tilde{x} + \tilde{y} = (x + y)(1 - \delta_{x+y}^{\text{dados}}) \quad \Leftarrow \quad \text{soma com dados errados}$$

$$\text{fl}(\tilde{x} + \tilde{y}) = (\tilde{x} + \tilde{y})(1 - \delta_{\tilde{x}+\tilde{y}}^{\text{arred}}) \quad \Leftarrow \quad \text{arredondamento da soma}$$

- Obtemos então para o **desvio relativo** acumulado

$$\delta_{x+y}^{\text{acum}} = \delta_{x+y}^{\text{dados}} + \delta_{\tilde{x}+\tilde{y}}^{\text{arred}} - \delta_{x+y}^{\text{dados}} \delta_{\tilde{x}+\tilde{y}}^{\text{arred}}$$

# Erros na aritmética de ponto flutuante

- O mesmo raciocínio vale para as outras operações aritméticas, e podemos concluir que para o desvio relativo acumulado  $\delta_{op}^{accum}$  em qualquer operação aritmética elemental temos

$$\delta_{op}^{accum} = \delta_{op}^{dados} + \delta_{op}^{arred} - \delta_{op}^{dados} \delta_{op}^{arred}$$

$\Downarrow$

$$\delta_{op}^{accum} = (1 - \delta_{op}^{arred}) \delta_{op}^{dados} + \delta_{op}^{arred}$$

$$\delta_{op}^{accum} = \underbrace{(1 - \delta_{op}^{arred})}_{\approx 1} \delta_{op}^{dados} + \delta_{op}^{arred}$$

$$\delta_{op}^{accum} \approx \delta_{op}^{dados} + \delta_{op}^{arred}$$

$$|\epsilon_{op}^{dados} - \epsilon_{op}^{arred}| \lesssim \epsilon_{op}^{accum} \lesssim \epsilon_{op}^{dados} + \epsilon_{op}^{arred}$$

- Assim, concluimos que o erro será muito maior que o erro de arredondamento, se e somente se o erro associado aos dados for muito grande.

# Erros na aritmética de ponto flutuante: Exemplo

Considere a função

$$f(x) = \frac{\sqrt{1+x} - 1}{x}, \quad \text{para } x \geq 0.$$

Quando  $x = 2 \cdot 10^q + 10^{2q}$  temos que  $f(x) = 1/(2 + 10^q)$ .


Tabela : Valores de  $f(x)$  calculados em Matlab.

| $q$ | $1/(2 + 10^q)$     | $x$        | $(\sqrt{1+x} - 1)/x$ |
|-----|--------------------|------------|----------------------|
| -15 | 0.5000000000000000 | 2.0000e-15 | 0.444089209850062    |
| -13 | 0.4999999999999975 | 2.0000e-13 | 0.499600361081295    |
| -11 | 0.4999999999997500 | 2.0000e-11 | 0.500000041367685    |
| -9  | 0.4999999997500000 | 2.0000e-09 | 0.499999930097883    |
| -7  | 0.4999999750000001 | 2.0000e-07 | 0.499999975291935    |
| -5  | 0.499997500012500  | 2.0000e-05 | 0.499997500015776    |
| -3  | 0.499750124937531  | 2.0010e-03 | 0.499750124937476    |
| -1  | 0.476190476190476  | 2.1000e-01 | 0.476190476190477    |

# Erros na aritmética de ponto flutuante: Exemplo

Na figura mostramos o erro relativo (acumulado) dividido pelo

$$\epsilon_{maq}: \epsilon_{f(x)} / \epsilon_{maq}.$$



# Erros na aritmética de ponto flutuante: Exemplo

Quando  $x$  é próximo de zero, temos um cancelamento catastrófico é os erros crescem de forma absurda! Chegando a ser  $\approx 10^{15} \epsilon_{maq}$ .

Será possível melhorar a precisão desses cálculos?

Observe que


$$f(x) = \left( \frac{\sqrt{1+x} - 1}{x} \right) \frac{\sqrt{1+x} + 1}{\sqrt{1+x} + 1} = \frac{(\sqrt{1+x})^2 - 1^2}{x(\sqrt{1+x} + 1)}$$

$\Downarrow$

$$f(x) = \frac{1}{\sqrt{1+x} + 1}.$$

Nessa expressão equivalente não temos cancelamento catastrófico! Mostramos os resultados para o erro relativo (acumulado), quando usamos a expressão acima nos cálculos.

# Erros na aritmética de ponto flutuante: Exemplo



# Em uma Galáxia muito, muito distante...





Donald E. Knuth,  
*The Art of Computer Programming.*  
vol. 2, Addison-Wesley, 1998.



Working Group for Floating-Point Arithmetic,  
*IEEE 754: Standard for Binary Floating-Point Arithmetic.*  
(<http://grouper.ieee.org/groups/754/index.html>)